

---

## Ejercicios - Conjuntos Convexos

Universidad Nacional de Colombia, Sede Bogotá

Introducción a la Optimización

2022-I

Sebastian Leonardo Molina Diaz

smolinad@unal.edu.co

---

## 2 Convex sets

### Exercises

- 2.1 Let  $C \subseteq \mathbb{R}^n$  be a convex set, with  $x_1, \dots, x_k \in C$ , and let  $\theta_1, \dots, \theta_k \in \mathbb{R}$  satisfy  $\theta_i \geq 0$ ,  $\theta_1 + \dots + \theta_k = 1$ . Show that  $\theta_1 x_1 + \dots + \theta_k x_k \in C$ . (The definition of convexity is that this holds for  $k = 2$ ; you must show it for arbitrary  $k$ ). *Hint.* Use induction on  $k$ .

*Solución.*

Sea  $C$  un conjunto convexo. Por definición de convexidad, se tiene el caso base con  $k = 2$ . Suponga que para  $k$  arbitrario se cumple que  $\sum_{i=1}^k \theta_i x_i \in C$ , con  $\sum_{i=1}^k \theta_i = 1$ ,  $\theta_i \geq 0$  y  $x_i \in C$  para  $1 \leq i \leq k$ . Sean  $\mu_j \geq 0$  y  $x_j \in C$  con  $1 \leq j \leq k+1$ . Para el paso inductivo, observe que si  $\mu_{k+1} = 0$ , obtenemos el mismo caso de la hipótesis de inducción. Si  $\mu_{k+1} = 1$ , estamos considerando el caso trivial en el que  $\mu_{k+1} x_{k+1} = 1 \cdot x_{k+1} = x_{k+1} \in C$ . Consideremos el caso en el que  $\mu_{k+1} \neq 0$  y  $\mu_{k+1} \neq 1$ . Observe que

$$\begin{aligned} \mathbf{y} &= \sum_{j=1}^{k+1} \mu_j x_j \\ &= \left( \frac{1 - \mu_{k+1}}{1 - \mu_{k+1}} \right) (\mu_1 x_1 + \mu_2 x_2 + \dots + \mu_k x_k) + \mu_{k+1} x_{k+1} \\ &= (1 - \mu_{k+1}) \cdot \left( \frac{\mu_1}{1 - \mu_{k+1}} x_1 + \frac{\mu_2}{1 - \mu_{k+1}} x_2 + \dots + \frac{\mu_k}{1 - \mu_{k+1}} x_k \right) + \mu_{k+1} x_{k+1} \\ &= (1 - \mu_{k+1}) \cdot (\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k) + \mu_{k+1} x_{k+1}, \end{aligned}$$

donde  $\lambda_l = \frac{\mu_l}{1 - \mu_{k+1}}$  con  $1 \leq l \leq k$ . De lo anterior, podemos notar que

$$\sum_{l=1}^k \lambda_l = \frac{\sum_{l=1}^k \mu_l}{1 - \mu_{k+1}} = \frac{1 - \mu_{k+1}}{1 - \mu_{k+1}} = 1.$$

Si denotamos  $\mathbf{x} = (\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k)$ , por hipótesis de inducción  $\mathbf{x} \in C$ , ya que  $\sum_{l=1}^k \lambda_l = 1$  y  $\lambda_l \geq 0$  para  $1 \leq l \leq k$ . Por lo tanto, como  $C$  es convexo,  $\mathbf{y} = (1 - \mu_{k+1}) \cdot \mathbf{x} + \mu_{k+1} x_{k+1} \in C$ .

□

- 2.3 *Midpoint convexity.* A set  $C$  is midpoint convex if whenever two points  $a, b$  are in  $C$ , the average or midpoint  $(a + b)/2$  is in  $C$ . Obviously a convex set is midpoint convex. It can be proved that under mild conditions midpoint convexity implies convexity. As a simple case, prove that if  $C$  is closed and midpoint convex, then  $C$  is convex. Considere el siguiente número binario, el cual codifica recursivamente

*Solución.*

Sean  $a, b \in C$ . Queremos ver que la combinación convexa  $\theta a + (1 - \theta)b \in C$ . Considere el coeficiente  $\theta_k$ , resultado de aplicar la convexidad de punto medio  $k$  veces a los puntos  $a$  y  $b$ , recursivamente. Entonces, podemos expresar a  $\theta_k$  como

$$\theta_k = \frac{\alpha_1}{2^1} + \frac{\alpha_2}{2^2} + \dots + \frac{\alpha_k}{2^k},$$

donde

$$\alpha_i = \begin{cases} 0 & |\theta| < |1 - \theta| \\ 1 & |1 - \theta| < |\theta| \end{cases}.$$

Observe que  $\lim_{k \rightarrow \infty} \theta_k a + (1 - \theta_k)b = \theta a + (1 - \theta)b \in C$ , ya que como  $C$  es cerrado, entonces contiene todos sus puntos límite. Por lo tanto,  $C$  es convexo. □

- 2.4 Show that the convex hull of a set  $S$  is the intersection of all convex sets that contain  $S$ . (The same method can be used to show that the conic, or affine, or linear hull of a set  $S$  is the intersection of all conic sets, or affine sets, or subspaces that contain  $S$ ).

*Solución.*

Usando doble contención, probemos que  $\text{conv } S = I$ , donde  $I = \bigcap \{C : S \subseteq C, C \text{ conjunto convexo}\}$ . Sea  $\mathbf{x} \in \text{conv } S$ , luego  $\mathbf{x} = \sum_{i=1}^n \theta_i x_i$ , donde  $\sum_{i=1}^n \theta_i = 1$ ,  $x_i \in S$  y  $x_i \in S$  para todo  $1 \leq i \leq n$ . Sea  $D$  un conjunto convexo arbitrario tal que  $S \subseteq D$ . Como  $D$  es convexo, cualquier combinación convexa de sus elementos está dentro de  $D$ , en particular  $\mathbf{x}$ . Como  $D$  es un conjunto arbitrario y  $\mathbf{x} \in I$  es un elemento arbitrario, entonces  $\text{conv } S \subseteq I$ . Ahora, note que  $S \subseteq \text{conv } S$  y  $\text{conv } S$  es convexo por definición. Así,  $\text{conv } S = C$  para algún  $C$  en la construcción de  $I$ . Luego  $I \subseteq \text{conv } S$ , y por lo tanto,  $I = \text{conv } S$ . □

- 2.5 What is the distance between two parallel hyperplanes  $\{x \in \mathbb{R}^n : a^T x = b_1\}$  and  $\{x \in \mathbb{R}^n : a^T x = b_2\}$ ?

*Solución.*

Sean  $\mathcal{H}_1 = \{x \in \mathbb{R}^n : a^T x = b_1\}$  y  $\mathcal{H}_2 = \{x \in \mathbb{R}^n : a^T x = b_2\}$  dos hiperplanos paralelos. La distancia entre  $\mathcal{H}_1$  y  $\mathcal{H}_2$  es la distancia entre dos puntos  $x_1 \in \mathcal{H}_1$  y  $x_2 \in \mathcal{H}_2$ , los cuales están sobre la recta normal a los hiperplanos que pasa por el origen, como se puede ver en la Figura 1.




Figura 1: Distancia entre hiperplanos paralelos.

Por lo tanto, si  $a$  es el vector normal a los hiperplanos,  $x_1$  y  $x_2$  son multiplicaciones escalares de  $a$ . Luego,  $x_1 = c_1 \cdot a$ , con  $c_1 \in \mathbb{R}$ . Como  $x_1 \in \mathcal{H}_1$ , entonces  $a^T x_1 = a^T (c_1 \cdot a) = b_1$ . Despejando, obtenemos que  $c_1 = b_1 / a^T a = b_1 / \|a\|^2$ , por lo que  $x_1 = (b_1 / \|a\|^2) a$ . Similarmente,  $x_2 = (b_2 / \|a\|^2) a$ . Así, la distancia entre  $\mathcal{H}_1$  y  $\mathcal{H}_2$  es

$$\begin{aligned} \|x_1 - x_2\| &= \left\| \frac{b_1}{\|a\|^2} a - \frac{b_2}{\|a\|^2} a \right\| = \left\| (b_1 - b_2) \frac{a}{\|a\|^2} \right\| \\ &= \frac{1}{\|a\|^2} |b_1 - b_2| \|a\| \\ &= \frac{|b_1 - b_2|}{\|a\|}. \end{aligned}$$

□

2.8 Which of the following sets  $S$  are polyhedra? If possible, express  $S$  in the form  $S = \{x : Ax \preceq b, Fx = g\}$ .

a)  $S = \{y_1 a_1 + y_2 a_2 : -1 \leq y_1 \leq 1, -1 \leq y_2 \leq 1\}$ , where  $a_1, a_2 \in \mathbb{R}^n$ .

*Solución.*

Observe que en los casos extremos en los que  $y_1 = \pm 1$  y  $y_2 = \pm 1$ , obtenemos cuatro puntos:  $a_1 + a_2, a_1 - a_2, -a_1 + a_2$  y  $-a_1 - a_2$ . Como  $-1 \leq y_1, y_2 \leq 1$ ,  $S$  define al paralelogramo con vértices en los cuatro puntos mencionados anteriormente, por lo que  $S$  es un poliedro.  $\square$

b)  $S = \{x \in \mathbb{R}^n : x \succeq 0, \mathbf{1}^T x = 1, \sum_{i=1}^n x_i a_i = b_1, \sum_{i=1}^n x_i a_i^2 = b_2\}$ , where  $a_1, \dots, a_n \in \mathbb{R}$  and  $b_1, b_2 \in \mathbb{R}$ .

*Solución.*

Sea  $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ . Claramente  $S$  es un poliedro ya que es la intersección de las igualdades  $\mathbf{1}^T x = 1$ ,  $\sum_{i=1}^n x_i a_i = b_1$ ,  $\sum_{i=1}^n x_i a_i^2 = b_2$  y las desigualdades  $x_j \geq 0$ , donde  $x_j$  con  $1 \leq j \leq n$  son las entradas de  $x$ .  $\square$

c)  $S = \{x \in \mathbb{R}^n : x \succeq 0, x^T y \leq 1 \text{ for all } y \text{ with } \|y\|_2 = 1\}$ .

*Solución.*

Si bien  $S$  es la intersección de semiespacios,  $S$  no es un poliedro ya que es la intersección de infinitos semiespacios definidos por los  $x \succeq 0$  tales que  $\|x\|_2 \leq 1$ , lo cual define la intersección de la bola unitaria en  $\mathbb{R}^n$  con  $\mathbb{R}_+^n$ .  $\square$

d)  $S = \{x \in \mathbb{R}^n : x \succeq 0, x^T y \leq 1 \text{ for all } y \text{ with } \sum_{i=1}^n |y_i| = 1\}$ .

*Solución.*

Por una idea similar a la del literal anterior,  $S$  es la intersección de  $\mathbb{R}_+^n$  con el conjunto  $\{x : |x_k| \leq 1, k \in \{1, \dots, n\}\}$ . Observe que si  $x \succeq 0$  tal que  $x^T y \leq 1$  para  $y$  con  $\sum_{i=1}^n |y_i| = 1$ , entonces podemos elegir a  $y$  tal que si  $|x_k| = \max\{x_i\}$  con  $1 \leq k \leq n$ , entonces

$$y_k = \begin{cases} 1 & x_k > 0, \\ -1 & x_k < 0, \\ 0 & \text{en otro caso.} \end{cases}$$

Con lo anterior obtenemos que

$$x^T y = \sum_{i=1}^n x_i y_i = y_k x_k = |x_k| = \max\{x_i\} \leq 1.$$

Por lo tanto,  $S$  es la intersección de  $\mathbb{R}_+^n$  con el conjunto finito  $\{x : -1 \leq x \leq 1\}$ . Así,  $S$  es un poliedro.  $\square$

2.9 *Voronoi sets and polyhedral decomposition.* Let  $x_0, \dots, x_K \in \mathbb{R}^n$ . Consider the set of points that are closer (in Euclidean norm) to  $x_0$  than the other  $x_i$ , i.e.,

$$V = \{x \in \mathbb{R}^n : \|x - x_0\|_2 \leq \|x - x_i\|_2, i = 1, \dots, K\}$$

$V$  is called the Voronoi region around  $x_0$  with respect to  $x_1, \dots, x_K$ .

a) Show that  $V$  is a polyhedron. Express  $V$  in the form  $V = \{x : Ax \preceq b\}$ .

*Solución.*

Sean  $x, x_0, \dots, x_K \in \mathbb{R}^n$ . Observe que  $x$  está mas cerca con la norma euclidiana a  $x_0$  que  $x_i$ , donde  $1 \leq i \leq K$ , si

$$\begin{aligned} \|x - x_0\|_2 &\leq \|x - x_i\|_2 \quad \therefore \|x - x_0\|_2^2 \leq \|x - x_i\|_2^2 \\ \therefore (x - x_0)^T (x - x_0) &\leq (x - x_i)^T (x - x_i) \\ \therefore x^T x - x^T x_0 - x_0^T x + x_0^T x_0 &\leq x^T x - x^T x_i - x_i^T x + x_i^T x_i \\ \therefore x^T x - 2x_0^T x - x_0^T x_0 &\leq x^T x - 2x_i^T x + x_i^T x_i \\ \therefore 2x_i^T x - 2x_0^T x &\leq x_i^T x_i - x_0^T x_0 \\ \therefore 2(x_i - x_0)^T x &\leq x_i^T x_i - x_0^T x_0, \end{aligned}$$

lo cual define un poliedro o un sistema de desigualdades lineales, donde  $V = \{x : Ax \leq b\}$  con

$$A = 2 \begin{bmatrix} x_1 - x_0 \\ x_1 - x_0 \\ \vdots \\ x_1 - x_K \end{bmatrix}^T, \quad b = \begin{bmatrix} x_1^T x_1 - x_0^T x_0 \\ x_2^T x_2 - x_0^T x_0 \\ \vdots \\ x_K^T x_K - x_0^T x_0 \end{bmatrix}.$$

Intuitivamente, como se puede ver en la Figura 2,  $V$  es la intersección de los semiespacios definidos por los hiperplanos ortogonales a  $x_i - x_0$ , que pasan por el punto medio  $m_i = \frac{x_0 + x_i}{2}$ , con  $1 \leq i \leq K$ .




Figura 2: Región de Voronoi alrededor de  $x_0$  como intersección de semiespacios.

□

- b) Conversely, given a polyhedron  $P$  with nonempty interior, show how to find  $x_0, \dots, x_K$  so that the polyhedron is the Voronoi region of  $x_0$  with respect to  $x_1, \dots, x_K$ .

*Solución.*

Sea  $V = \{Ax \leq b\}$  un poliedro con interior no vacío. Intuitivamente, tomando como referencia la Figura 2, para construir la región de Voronoi tome cualquier punto dentro del poliedro como  $x_0$ . Luego, tome el punto  $x_i$ , simétrico respecto a los hiperplanos definidos por  $v_i^T x = b_i$ . Para ello, debemos tomar a  $x_i = x_0 + \delta a_i$  tal que su distancia al hiperplano es igual a la distancia de  $x_0$  al hiperplano. Es decir

$$a_i^T x_i - b_i = b_i - a_i^T x_0.$$

Reemplazando  $x_i$  en la igualdad anterior obtenemos que

$$\begin{aligned} a_i^T (x_0 + \delta a_i) - b_i &= b_i - a_i^T x_0 \quad \therefore 0 = 2b_i - a_i^T x_0 - a_i^T (x_0 + \delta a_i) \\ \therefore 0 &= 2b_i - 2a_i^T x_0 - \delta a_i^T a_i \\ \therefore 2b_i - 2a_i^T x_0 &= \delta a_i^T a_i \\ \therefore \frac{2(b_i - a_i^T x_0)}{a_i^T a_i} &= \frac{2(b_i - a_i^T x_0)}{\|a\|^2} = \delta. \end{aligned}$$

$$\text{Así, } x_i = x_0 + \frac{2(b_i - a_i^T x_0)}{\|a\|^2} a_i.$$


□

- c) We can also consider the sets

$$V_k = \{x \in \mathbb{R}^n : \|x - x_k\|_2 \leq \|x - x_i\|_2, i \neq k\}$$

The set  $V_k$  consists of points in  $\mathbb{R}^n$  for which the closest point in the set  $\{x_0, \dots, x_K\}$  is  $x_k$ . The sets  $V_0, \dots, V_K$  give a polyhedral decomposition of  $\mathbb{R}^n$ . More precisely, the sets  $V_k$  are polyhedra,  $\bigcup_{k=0}^K V_k = \mathbb{R}^n$ , and  $\text{int } V_i \cap \text{int } V_j = \emptyset$  for  $i \neq j$ , i.e.,  $V_i$  and  $V_j$  intersect at most along a boundary. Suppose that  $P_1, \dots, P_m$  are polyhedra such that  $\bigcup_{i=1}^m P_i = \mathbb{R}^n$ , and  $\text{int } P_i \cap \text{int } P_j = \emptyset$  for  $i \neq j$ . Can this polyhedral decomposition of  $\mathbb{R}^n$  be described as the Voronoi regions generated by an appropriate set of points?

Considere dos hiperplanos  $\mathcal{H}_1, \mathcal{H}_2 \subset \mathbb{R}^2$ , los cuales no son paralelos. Considere que el ángulo entre los hiperplanos  $\theta$  es tal que  $0 < \theta < \frac{\pi}{3}$ . Sean  $x_1 \in P_1$  y  $x_2 \in P_2$  dos puntos arbitrarios. Note que el punto  $\hat{x}_1$ , el cual es el reflejo de  $x_1$  respecto a  $\mathcal{H}_1$  está en  $\hat{P}_1 \subset P_4$ . Similarmente, el punto  $\hat{x}_2$ , el cual es el reflejo de  $x_2$  respecto a  $\mathcal{H}_2$  está en  $\hat{P}_2 \subset P_4$ . Sin embargo, no es posible construir el punto  $\hat{x}_3 \in P_4$ , el cual debe ser la reflexión de  $x_1$  y  $x_2$  respecto a  $\mathcal{H}_1$  y  $\mathcal{H}_2$  simultáneamente, ya que  $\hat{P}_1 \cap \hat{P}_2 = \emptyset$ .

☐
$$C = \{x \in \mathbb{R}^n : x^T A x + b^T x + c \leq 0\}$$

a) Show that  $C$  is convex if  $A \succeq 0$ .

Un conjunto es convexo si su intersección con una línea arbitraria  $y + tv$  es convexa. Considere entonces lo siguiente:

$$\begin{aligned} (y + tv)^T A(y + tv) + b^T(y + tv) + c &= (y^T A + tv^T A)(y + tv) + b^T y + b^T tv + c \\ &= y^T A y + 2y^T A tv + tv^T A tv + b^T y + b^T tv + c \\ &= (v^T A v)t^2 + (2y^T A tv + b^T tv) + (b^T y + y^T A y + c) \\ &= (v^T A v)t^2 + (2y^T A v + b^T v)t + (b^T y + y^T A y + c) \\ &= \gamma t^2 + \mu t + \phi. \end{aligned}$$

☐

Sea  $B = A + \lambda g g^T$ , entonces  $A = B - \lambda g g^T$ . Reemplazando en la desigualdad cuadrática:

$$\begin{aligned} x^T Ax + b^T x + c &\leq 0 \therefore x^T (B - \lambda g g^T) x + b^T x + c \leq 0 \\ &\therefore x^T B x - \lambda x^T g g^T x + b^T x + c \leq 0 \\ &\therefore x^T B x + b^T x + (c - \lambda x^T g g^T x) \leq 0. \end{aligned}$$

Por el literal anterior sabemos que el conjunto solución de la desigualdad obtenida es convexo, ya que  $B \succeq 0$ . Justamente, esta desigualdad representa la intersección entre  $C$  y el hiperplano, el cual también es convexo.  $\square$

**2.13 Conic hull of outer products.** Consider the set of rank- $k$  outer products, defined as  $\{XX^T : X \in \mathbb{R}^{n \times k}, \text{rank } X = k\}$ . Describe its conic hull in simple terms.

*Solución.*

Sea  $\mathcal{O} = \{XX^T : X \in \mathbb{R}^{n \times k}, \text{rank } X = k\}$ . Observe que  $XX^T$  es semidefinida positiva, ya que para un vector real  $y$ ,  $y^T XX^T y = z^T z = \|z\|^2 \geq 0$ , con  $z = X^T y$ . Además, sabemos que  $\text{rank } XX^T = \text{rank } X^T X = \text{rank } X^T = \text{rank } X = k$ . Sean  $A, B \in \mathcal{O}$  matrices semidefinidas positivas tal que  $\text{rank } A = \text{rank } B = k$ . Sea  $v \in \ker(A + B)$ , entonces

$$(A + B)v = 0 \quad \therefore \quad v^T(A + B)v = 0 \quad \therefore \quad v^T A v + v^T B v = 0,$$

por lo que  $v^T A v = v^T B v = 0$ , y en particular  $A v = B v = 0$ . Por lo tanto,  $v$  está en los espacios nulos de  $A$  y  $B$ , es decir,  $v \in \ker A$  y  $v \in \ker B$ . Así,  $\dim(\ker(A + B)) \leq \dim(\ker A) + \dim(\ker B)$ , y por el teorema de rango-nulidad, cualquier combinación  $\gamma A + \delta B$  con  $\gamma, \delta \geq 0$  debe tener rango mayor o igual que  $k$ , ya que al disminuir la nulidad, aumenta el rango. Por lo tanto, **cone**  $\mathcal{O} = \{A : A \text{ es semidefinida positiva, } \text{rank } A \geq k\} \cup \{0_{n \times n}\}$ .  $\square$

**2.14 Expanded and restricted sets.** Let  $S \subseteq \mathbb{R}^n$ , and let  $\|\cdot\|$  be a norm on  $\mathbb{R}^n$ .

- a) For  $a \geq 0$  we define  $S_a$  as  $\{x : \text{dist}(x, S) \leq a\}$ , where  $\text{dist}(x, S) = \inf_{y \in S} \|x - y\|$ . We refer to  $S_a$  as  $S$  expanded or extended by  $a$ . Show that if  $S$  is convex, then  $S_a$  is convex.

*Solución.*

Sean  $x, z \in S_a$ . Queremos ver que la combinación convexa  $\theta x + (1 - \theta)z \in S_a$ . Note que

$$\text{dist}(\theta x + (1 - \theta)z, S) = \inf_{y \in S} \|\theta x + (1 - \theta)z - y\|.$$

Como  $y \in S$  y  $S$  es convexo, considere el caso particular  $y = \theta y_1 + (1 - \theta)y_2$ . Luego,

$$\begin{aligned} \text{dist}(\theta x + (1 - \theta)z, S) &= \inf_{y_1, y_2 \in S} \|\theta x + (1 - \theta)z - \theta y_1 - (1 - \theta)y_2\| \\ &= \inf_{y_1, y_2 \in S} \|\theta(x - y_1) + (1 - \theta)(z - y_2)\| \\ &\leq \theta \inf_{y_1 \in S} \|x - y_1\| + (1 - \theta) \inf_{y_2 \in S} \|z - y_2\| \\ &\leq (\theta + (1 - \theta))a \\ &\leq a. \end{aligned}$$

$\square$

- b) For  $a \geq 0$  we define  $S_{-a} = \{x : B(x, a) \subseteq S\}$ , where  $B(x, a)$  is the ball (in the norm  $\|\cdot\|$ ), centered at  $x$ , with radius  $a$ . We refer to  $S_{-a}$  as  $S$  shrunk or restricted by  $a$ , since  $S_{-a}$  consists of all points that are at least a distance  $a$  from  $\mathbb{R}^n \setminus S$ . Show that if  $S$  is convex, then  $S_{-a}$  is convex.

*Solución.*

Sean  $x, y \in S_{-a}$ , y sea  $z$  tal que  $|z| \leq a$ . Entonces  $x + z, y + z \in S$ , por lo que para  $0 \leq \theta \leq 1$  se tiene que  $\theta x + (1 - \theta)y + z \in S$ , ya que  $S$  es convexo. Por lo tanto  $\theta x + (1 - \theta)y \in S_{-a}$ .  $\square$

**2.15 Some sets of probability distributions.** Let  $x$  be a real-valued random variable with  $\mathbf{prob}(x = a_i) = p_i, i = 1, \dots, n$ , where  $a_1 < a_2 < \dots < a_n$ . Of course  $p \in \mathbb{R}^n$  lies in the standard probability simplex  $P = \{p : \mathbf{1}^T p = 1, p \succeq 0\}$ . Which of the following conditions are convex in  $p$ ? (That is, for which of the following conditions is the set of  $p \in P$  that satisfy the condition convex?)

- a)  $\alpha \leq \mathbf{E} f(x) \leq \beta$ , where  $\mathbf{E} f(x)$  is the expected value of  $f(x)$ , i.e.,  $\mathbf{E} f(x) = \sum_{i=1}^n p_i f(a_i)$ . (The function  $f : \mathbb{R} \rightarrow \mathbb{R}$  is given.)

*Solución.*

Esta condición es convexa en  $p$ , ya que es equivalente a la desigualdad lineal  $\alpha \leq \sum_{i=1}^n p_i f(a_i) \leq \beta$ . □

b)  $\mathbf{prob}(x > \alpha) \leq \beta$ .

*Solución.*

Esta condición es convexa en  $p$ , ya que es equivalente a la desigualdad lineal  $\sum_{i: a_i \geq \alpha} p_i \leq \beta$ . □

c)  $\mathbf{E}|x^3| \leq \alpha \mathbf{E}|x|$ .

*Solución.*

Esta condición es convexa en  $p$ , ya que es equivalente a la desigualdad lineal

$$\sum_{i=1}^n p_i |a_i|^3 \leq \alpha \sum_{i=1}^n p_i |a_i| = \sum_{i=1}^n p_i (|a_i|^3 - \alpha |a_i|) \leq 0.$$

□

d)  $\mathbf{E} x^2 \leq \alpha$ .

*Solución.*

Esta condición es convexa en  $p$ , ya que es equivalente a la desigualdad lineal  $\sum_{i=1}^n p_i (a_i)^2 \leq \alpha$ . □

e)  $\mathbf{E} x^2 \geq \alpha$ .

*Solución.*

Esta condición es convexa en  $p$ , ya que es similar a la del literal anterior. □

f)  $\mathbf{var}(x) \leq \alpha$ , where  $\mathbf{var}(x) = \mathbf{E}(x - \mathbf{E} x)^2$  is the variance of  $x$ .

*Solución.*

Considere la distribución de probabilidad  $\{\mathbf{prob}(x = a_1 = 0) = 0, \mathbf{prob}(x = a_2 = 1) = 1\}$ . Sea  $\alpha = \frac{1}{8}$ . Entonces

$$\mathbf{var}(x) = (0 \cdot 0^2 + 1 \cdot 1^2) - (0 \cdot 0 + 1 \cdot 1)^2 = 1 - 1 = 0 \leq \frac{1}{8}.$$

Sin embargo, al considerar la distribución  $\{\mathbf{prob}(x = a_1 = 0) = \frac{1}{3}, \mathbf{prob}(x = a_2 = 1) = \frac{2}{3}\}$ , podemos ver que  $\mathbf{var}(x)$  no es convexa en general, ya que

$$\left(\frac{1}{3} \cdot 0^2 + \frac{2}{3} \cdot 1^2\right) - \left(\frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1\right)^2 = \frac{2}{9} \not\leq \frac{1}{8}.$$

□

g)  $\mathbf{var}(x) \geq \alpha$ .

*Solución.*

Observe que esta condición la podemos reescribir como

$$\begin{aligned} \sum_{i=1}^n p_i (a_i)^2 - \left(\sum_{i=1}^n p_i a_i\right)^2 &\geq \alpha \therefore -\sum_{i=1}^n p_i (a_i)^2 + \left(\sum_{i=1}^n p_i a_i\right)^2 \leq \alpha \\ &\therefore b^T p + p^T a a^T p \leq \alpha, \end{aligned}$$

donde  $b = a_i^2$ . Esto es un conjunto convexo dado que  $a a^T$  es semidefinida positiva. □

h)  $\mathbf{quartile}(x) \geq \alpha$ , where  $\mathbf{quartile}(x) = \inf\{\beta : \mathbf{prob}(x \leq \beta) \geq 0.25\}$ .

*Solución.*

Observe que si  $\alpha \leq a_1$ , la condición se cumple trivialmente. En otro caso, ver que  $\inf\{\beta : \mathbf{prob}(x \leq \beta) \geq 0.25\} \geq \alpha$  corresponde a ver la condición  $\mathbf{prob}(x \leq \beta) < \alpha$  para todo  $\beta < \alpha$ . Por lo tanto, si definimos a  $j = \max\{i : a_i \leq \alpha\}$ , entonces

$$\mathbf{prob}(x \leq a_j) = \sum_{i=0}^j p_i < 0.25$$

define una desigualdad lineal, que a su vez define un semiespacio abierto. □

i) **quartile**( $x$ )  $\leq \alpha$ .

*Solución.*

Por un razonamiento similar al del literal anterior, ver que  $\inf\{\beta : \mathbf{prob}(x \leq \beta) \geq 0.25\} \leq \alpha$  corresponde a ver la condición  $\mathbf{prob}(x \leq \beta) \geq \alpha$  para todo  $\beta \geq \alpha$ . Esto es justamente el caso dual al literal anterior, por lo que esta condición corresponde a la desigualdad lineal definida por

$$\mathbf{prob}(x \leq a_{j+1}) = \sum_{i=j+1}^n p_i \geq 0.25.$$

□

**2.16** Show that if  $S_1$  and  $S_2$  are convex sets in  $\mathbb{R}^{m+n}$ , then so is their partial sum

$$S = \{(x, y_1 + y_2) : x \in \mathbb{R}^m, y_1, y_2 \in \mathbb{R}^n, (x, y_1) \in S_1, (x, y_2) \in S_2\}$$

*Solución.*

Sean  $\mathbf{x}_1, \mathbf{x}_2 \in S$  tales que  $x_1 = (\tilde{x}, \tilde{y}_1 + \tilde{y}_2)$ ,  $x_2 = (\hat{x}, \hat{y}_1 + \hat{y}_2)$  tal que  $(\tilde{x}, \tilde{y}_1), (\hat{x}, \hat{y}_1) \in S_1$  y  $(\tilde{x}, \tilde{y}_2), (\hat{x}, \hat{y}_2) \in S_2$ . Considere la siguiente combinación convexa:

$$\begin{aligned} \mathbf{x}_1 + \mathbf{x}_2 &= \theta(\tilde{x}, \tilde{y}_1 + \tilde{y}_2) + (1 - \theta)(\hat{x}, \hat{y}_1 + \hat{y}_2) \\ &= (\theta\tilde{x}, \theta\tilde{y}_1 + \theta\tilde{y}_2) + ((1 - \theta)\hat{x}, (1 - \theta)\hat{y}_1 + (1 - \theta)\hat{y}_2) \\ &= (\theta\tilde{x} + (1 - \theta)\hat{x}, (\theta\tilde{y}_1 + (1 - \theta)\hat{y}_1) + (\theta\tilde{y}_2 + (1 - \theta)\hat{y}_2)) \end{aligned}$$

Como  $S_1$  y  $S_2$  son convexos, entonces  $(\theta\tilde{x} + (1 - \theta)\hat{x}, \theta\tilde{y}_1 + (1 - \theta)\hat{y}_1) \in S_1$  y  $(\theta\tilde{x} + (1 - \theta)\hat{x}, \theta\tilde{y}_2 + (1 - \theta)\hat{y}_2) \in S_2$ . Por lo tanto,  $\mathbf{x}_1 + \mathbf{x}_2 \in S$ . □

**2.17** *Image of polyhedral sets under perspective function.* In this problem we study the image of hyperplanes, halfspaces, and polyhedra under the perspective function  $P(x, t) = x/t$ , with  $\text{dom } P = \mathbb{R}^n \times \mathbb{R}_{++}$ . For each of the following sets  $C$ , give a simple description of

$$P(C) = \{v/t : (v, t) \in C, t > 0\}.$$

a) The polyhedron  $C = \mathbf{conv}\{(v_1, t_1), \dots, (v_K, t_K)\}$  where  $v_i \in \mathbb{R}^n$  and  $t_i > 0$ .

*Solución.*

Observe que  $P(C) = \mathbf{conv}\{\frac{v}{t} : (v, t) \in C, t > 0\}$ . Esto se obtiene por doble contención y por el resultado de la inducción del **Ejercicio 2.1**. □

b) The hyperplane  $C = \{(v, t) : f^T v + gt = h\}$  (with  $f$  and  $g$  not both zero).

*Solución.*

Como  $t > 0$ , observe que  $P(C) = \left\{w = \frac{v}{t} : \frac{f^T v + gt}{t} = \frac{h}{t}\right\} = \left\{w : f^T w + g = \frac{h}{t}\right\}$ . Es decir,

$$P(C) = \begin{cases} \{w : f^T w + g = 0\} & h = 0, \\ \{w : f^T w + g < 0\} & h < 0, \\ \{w : f^T w + g > 0\} & h > 0. \end{cases}$$

□



c) The halfspace  $C = \{(v, t) : f^T v + gt \leq h\}$  (with  $f$  and  $g$  not both zero).

*Solución.*

De manera similar al literal anterior, como  $t > 0$ , observe que

$$P(C) = \left\{ w = \frac{v}{t} : \frac{f^T v + gt}{t} \leq \frac{h}{t} \right\} = \left\{ w : f^T w + g \leq \frac{h}{t} \right\}.$$

Es decir,

$$P(C) = \begin{cases} \{w : f^T w + g \leq 0\} & h = 0, \\ \{w : f^T w + g < 0\} & h < 0, \\ \{w : f^T w + g > 0\} = \mathbb{R}^n & h > 0. \end{cases}$$

□

d) The polyhedron  $C = \{(v, t) : Fv + gt \preceq h\}$ .

*Solución.*

Observe que

$$P(C) = \left\{ w = \frac{v}{t} : \frac{Fv + gt}{t} \preceq \frac{h}{t} \right\} = \left\{ w : Fw + g \preceq \frac{h}{t} \right\}.$$

Luego,  $w \in P(C)$  si cumple los dos primeros casos de la proyección del literal anterior para cualquier vector columna  $f_i$  de  $F$ , y además, si  $h_i > 0$  y  $h_j < 0$  entonces  $\frac{f_i^T w + g_i}{h_i} \leq \frac{f_j^T w + g_j}{h_j}$ .

□

**2.18 Invertible linear-fractional functions.** Let  $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$  be the linear-fractional function

$$f(x) = (Ax + b)/(c^T x + d), \quad \text{dom } f = \{x : c^T x + d > 0\}$$

Suppose the matrix

$$Q = \begin{bmatrix} A & b \\ c^T & d \end{bmatrix}$$

is nonsingular. Show that  $f$  is invertible and that  $f^{-1}$  is a linear-fractional mapping. Give an explicit expression for  $f^{-1}$  and its domain in terms of  $A, b, c$ , and  $d$ . *Hint.* It may be easier to express  $f^{-1}$  in terms of  $Q$ .

*Solución.*

Sea  $x \in \mathbb{R}^n$ . Considere la función  $\mathcal{P}(x) = \{s(x, 1) : s \geq 0\}$ , la cual envía a vectores en  $\mathbb{R}^n$  en rayos de  $\mathbb{R}^{n+1}$ . Sea  $P$  la función perspectiva, entonces  $f$  puede ser expresada como

$$\begin{aligned} P(Q\mathcal{P}(x)) &= P(Q \cdot s(x, 1)) \\ &= P\left(\begin{bmatrix} A & b \\ c^T & d \end{bmatrix} \begin{pmatrix} sx \\ s \end{pmatrix}\right) \\ &= P\left(\begin{bmatrix} s(Ax + b) \\ s(c^T x + d) \end{bmatrix}\right) \\ &= \frac{s(Ax + b)}{s(c^T x + d)} = \frac{Ax + b}{c^T x + d} \\ &= f(x). \end{aligned}$$

Como  $P$ ,  $\mathcal{P}$  y  $Q$  tienen inversas — $Q$  tiene inversa ya que es no singular—, entonces la inversa de  $f$  es

$$f^{-1}(x) = \mathcal{P}^{-1}(Q^{-1}P^{-1}(x)).$$

□

## Ejercicios adicionales

2. Implementar un algoritmo para determinar si un punto está en el cono convexo de un conjunto de puntos en cualquier dimensión.

*Solución.*

La solución está implementada en el notebook de **julia** en <https://github.com/smolina/IntroductionToOptimization/tree/main/Convex%20Sets>.

□

3. Verificar que el conjunto de soluciones de un conjunto de desigualdades de matrices lineales es convexa.

*Solución.*

Sea  $\mathcal{A}(x) = [A_1, A_2, \dots, A_n] (x_1, x_2, \dots, x_n)^T$ . Considere la desigualdad lineal de matrices

$$\mathcal{A}(x) = x_1 A_1 + x_2 A_2 + x_3 A_3 + \dots + x_n A_n \preceq B.$$

Note que la solución de la desigualdad anterior es el conjunto  $\{x : \mathcal{A}(x) \preceq B\} = f^{-1}(\mathbf{S}_+^m)$ , donde  $f$  es la función afín  $f : \mathbb{R}^n \rightarrow \mathbf{S}^m$  definida por  $f(x) = B - \mathcal{A}(x)$ . Que el conjunto  $\{x : \mathcal{A}(x) \preceq B\}$  sea convexo sigue de que  $f$  es afín.

□

## Referencias

- [1] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2009.