
Ejercicios - Conjuntos Convexos

Universidad Nacional de Colombia, Sede Bogotá

Introducción a la Optimización

2022-I

Sebastian Leonardo Molina Diaz

smolinad@unal.edu.co

2 Convex sets

Exercises

- 2.1 Let $C \subseteq \mathbb{R}^n$ be a convex set, with $x_1, \dots, x_k \in C$, and let $\theta_1, \dots, \theta_k \in \mathbb{R}$ satisfy $\theta_i \geq 0$, $\theta_1 + \dots + \theta_k = 1$. Show that $\theta_1 x_1 + \dots + \theta_k x_k \in C$. (The definition of convexity is that this holds for $k = 2$; you must show it for arbitrary k). *Hint.* Use induction on k .

Solución.

Sea C un conjunto convexo. Por definición de convexidad, se tiene el caso base con $k = 2$. Suponga que para k arbitrario se cumple que $\sum_{i=1}^k \theta_i x_i \in C$, con $\sum_{i=1}^k \theta_i = 1$, $\theta_i \geq 0$ y $x_i \in C$ para $1 \leq i \leq k$. Sean $\mu_j \geq 0$ y $x_j \in C$ con $1 \leq j \leq k+1$. Para el paso inductivo, observe que si $\mu_{k+1} = 0$, obtenemos el mismo caso de la hipótesis de inducción. Si $\mu_{k+1} = 1$, estamos considerando el caso trivial en el que $\mu_{k+1} x_{k+1} = 1 \cdot x_{k+1} = x_{k+1} \in C$. Consideremos el caso en el que $\mu_{k+1} \neq 0$ y $\mu_{k+1} \neq 1$. Observe que

$$\begin{aligned} \mathbf{y} &= \sum_{j=1}^{k+1} \mu_j x_j \\ &= \left(\frac{1 - \mu_{k+1}}{1 - \mu_{k+1}} \right) (\mu_1 x_1 + \mu_2 x_2 + \dots + \mu_k x_k) + \mu_{k+1} x_{k+1} \\ &= (1 - \mu_{k+1}) \cdot \left(\frac{\mu_1}{1 - \mu_{k+1}} x_1 + \frac{\mu_2}{1 - \mu_{k+1}} x_2 + \dots + \frac{\mu_k}{1 - \mu_{k+1}} x_k \right) + \mu_{k+1} x_{k+1} \\ &= (1 - \mu_{k+1}) \cdot (\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k) + \mu_{k+1} x_{k+1}, \end{aligned}$$

donde $\lambda_l = \frac{\mu_l}{1 - \mu_{k+1}}$ con $1 \leq l \leq k$. De lo anterior, podemos notar que

$$\sum_{l=1}^k \lambda_l = \frac{\sum_{l=1}^k \mu_l}{1 - \mu_{k+1}} = \frac{1 - \mu_{k+1}}{1 - \mu_{k+1}} = 1.$$

Si denotamos $\mathbf{x} = (\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_k x_k)$, por hipótesis de inducción $\mathbf{x} \in C$, ya que $\sum_{l=1}^k \lambda_l = 1$ y $\lambda_l \geq 0$ para $1 \leq l \leq k$. Por lo tanto, como C es convexo, $\mathbf{y} = (1 - \mu_{k+1}) \cdot \mathbf{x} + \mu_{k+1} x_{k+1} \in C$.

□

- 2.3 *Midpoint convexity.* A set C is midpoint convex if whenever two points a, b are in C , the average or midpoint $(a + b)/2$ is in C . Obviously a convex set is midpoint convex. It can be proved that under mild conditions midpoint convexity implies convexity. As a simple case, prove that if C is closed and midpoint convex, then C is convex. Considere el siguiente número binario, el cual codifica recursivamente

Solución.

Sean $a, b \in C$. Queremos ver que la combinación convexa $\theta a + (1 - \theta)b \in C$. Considere el coeficiente θ_k , resultado de aplicar la convexidad de punto medio k veces a los puntos a y b , recursivamente. Entonces, podemos expresar a θ_k como

$$\theta_k = \frac{\alpha_1}{2^1} + \frac{\alpha_2}{2^2} + \dots + \frac{\alpha_k}{2^k},$$

donde

$$\alpha_i = \begin{cases} 0 & |\theta| < |1 - \theta| \\ 1 & |1 - \theta| < |\theta| \end{cases}.$$

Observe que $\lim_{k \rightarrow \infty} \theta_k a + (1 - \theta_k)b = \theta a + (1 - \theta)b \in C$, ya que como C es cerrado, entonces contiene todos sus puntos límite. Por lo tanto, C es convexo. □

- 2.4 Show that the convex hull of a set S is the intersection of all convex sets that contain S . (The same method can be used to show that the conic, or affine, or linear hull of a set S is the intersection of all conic sets, or affine sets, or subspaces that contain S).

Solución.

Usando doble contención, probemos que $\text{conv } S = I$, donde $I = \bigcap \{C : S \subseteq C, C \text{ conjunto convexo}\}$. Sea $\mathbf{x} \in \text{conv } S$, luego $\mathbf{x} = \sum_{i=1}^n \theta_i x_i$, donde $\sum_{i=1}^n \theta_i = 1$, $x_i \in S$ y $x_i \in S$ para todo $1 \leq i \leq n$. Sea D un conjunto convexo arbitrario tal que $S \subseteq D$. Como D es convexo, cualquier combinación convexa de sus elementos está dentro de D , en particular \mathbf{x} . Como D es un conjunto arbitrario y $\mathbf{x} \in I$ es un elemento arbitrario, entonces $\text{conv } S \subseteq I$. Ahora, note que $S \subseteq \text{conv } S$ y $\text{conv } S$ es convexo por definición. Así, $\text{conv } S = C$ para algún C en la construcción de I . Luego $I \subseteq \text{conv } S$, y por lo tanto, $I = \text{conv } S$. □

- 2.5 What is the distance between two parallel hyperplanes $\{x \in \mathbb{R}^n : a^T x = b_1\}$ and $\{x \in \mathbb{R}^n : a^T x = b_2\}$?

Solución.

Sean $\mathcal{H}_1 = \{x \in \mathbb{R}^n : a^T x = b_1\}$ y $\mathcal{H}_2 = \{x \in \mathbb{R}^n : a^T x = b_2\}$ dos hiperplanos paralelos. La distancia entre \mathcal{H}_1 y \mathcal{H}_2 es la distancia entre dos puntos $x_1 \in \mathcal{H}_1$ y $x_2 \in \mathcal{H}_2$, los cuales están sobre la recta normal a los hiperplanos que pasa por el origen, como se puede ver en la Figura 1.




Figura 1: Distancia entre hiperplanos paralelos.

Por lo tanto, si a es el vector normal a los hiperplanos, x_1 y x_2 son multiplicaciones escalares de a . Luego, $x_1 = c_1 \cdot a$, con $c_1 \in \mathbb{R}$. Como $x_1 \in \mathcal{H}_1$, entonces $a^T x_1 = a^T (c_1 \cdot a) = b_1$. Despejando, obtenemos que $c_1 = b_1 / a^T a = b_1 / \|a\|^2$, por lo que $x_1 = (b_1 / \|a\|^2) a$. Similarmente, $x_2 = (b_2 / \|a\|^2) a$. Así, la distancia entre \mathcal{H}_1 y \mathcal{H}_2 es

$$\begin{aligned} \|x_1 - x_2\| &= \left\| \frac{b_1}{\|a\|^2} a - \frac{b_2}{\|a\|^2} a \right\| = \left\| (b_1 - b_2) \frac{a}{\|a\|^2} \right\| \\ &= \frac{1}{\|a\|^2} |b_1 - b_2| \|a\| \\ &= \frac{|b_1 - b_2|}{\|a\|}. \end{aligned}$$

□

2.8 Which of the following sets S are polyhedra? If possible, express S in the form $S = \{x : Ax \preceq b, Fx = g\}$.

- a) $S = \{y_1 a_1 + y_2 a_2 : -1 \leq y_1 \leq 1, -1 \leq y_2 \leq 1\}$, where $a_1, a_2 \in \mathbb{R}^n$.
- b) $S = \{x \in \mathbb{R}^n : x \geq 0, \mathbf{1}^T x = 1, \sum_{i=1}^n x_i a_i = b_1, \sum_{i=1}^n x_i a_i^2 = b_2\}$, where $a_1, \dots, a_n \in \mathbb{R}$ and $b_1, b_2 \in \mathbb{R}$.
- c) $S = \{x \in \mathbb{R}^n : x \geq 0, x^T y \leq 1 \text{ for all } y \text{ with } \|y\|_2 = 1\}$.
- d) $S = \{x \in \mathbb{R}^n : x \geq 0, x^T y \leq 1 \text{ for all } y \text{ with } \sum_{i=1}^n |y_i| = 1\}$.

2.9 *Voronoi sets and polyhedral decomposition.* Let $x_0, \dots, x_K \in \mathbb{R}^n$. Consider the set of points that are closer (in Euclidean norm) to x_0 than the other x_i , i.e.,

$$V = \{x \in \mathbb{R}^n : \|x - x_0\|_2 \leq \|x - x_i\|_2, i = 1, \dots, K\}$$

V is called the Voronoi region around x_0 with respect to x_1, \dots, x_K .

- a) Show that V is a polyhedron. Express V in the form $V = \{x : Ax \preceq b\}$.

Solución.

Sean $x, x_0, \dots, x_K \in \mathbb{R}^n$. Observe que x está mas cerca con la norma euclidiana a x_0 que x_i , donde $1 \leq i \leq K$, si

$$\begin{aligned} \|x - x_0\|_2 &\leq \|x - x_i\|_2 \quad \therefore \|x - x_0\|_2^2 \leq \|x - x_i\|_2^2 \\ &\therefore (x - x_0)^T (x - x_0) \leq (x - x_i)^T (x - x_i) \\ &\therefore x^T x - x^T x_0 - x_0^T x + x_0^T x_0 \leq x^T x - x^T x_i - x_i^T x + x_i^T x_i \\ &\therefore x^T x - 2x_0^T x - x_0^T x_0 \leq x^T x - 2x_i^T x + x_i^T x_i \\ &\therefore 2x_i^T x - 2x_0^T x \leq x_i^T x_i - x_0^T x_0 \\ &\therefore 2(x_i - x_0)^T x \leq x_i^T x_i - x_0^T x_0, \end{aligned}$$

lo cual define un poliedro o un sistema de desigualdades lineales, donde $V = \{x : Ax \preceq b\}$ con

$$A = 2 \begin{bmatrix} x_1 - x_0 \\ x_1 - x_0 \\ \vdots \\ x_1 - x_K \end{bmatrix}^T, \quad b = \begin{bmatrix} x_1^T x_1 - x_0^T x_0 \\ x_2^T x_2 - x_0^T x_0 \\ \vdots \\ x_K^T x_K - x_0^T x_0 \end{bmatrix}.$$

Intuitivamente, como se puede ver en la Figura 2, V es la intersección de los semiespacios definidos por los hiperplanos ortogonales a $x_i - x_0$, que pasan por el punto medio $m_i = \frac{x_0 + x_i}{2}$, con $1 \leq i \leq K$.




Figura 2: Región de Voronoi alrededor de x_0 como intersección de semiespacios.

□

- b) Conversely, given a polyhedron P with nonempty interior, show how to find x_0, \dots, x_K so that the polyhedron is the Voronoi region of x_0 with respect to x_1, \dots, x_K .

Solución.

Sea $V = \{Ax \leq b\}$ un poliedro con interior no vacío. Intuitivamente, tomando como referencia la Figura 2, para construir la región de Voronoi tome cualquier punto dentro del poliedro como x_0 . Luego, tome el punto x_i , simétrico respecto a los hiperplanos definidos por $v_i^T x = b_i$. Para ello, debemos tomar a $x_i = x_0 + \delta a_i$ tal que su distancia al hiperplano es igual a la distancia de x_0 al hiperplano. Es decir

$$a_i^T x_i - b_i = b_i - a_i^T x_0.$$

Reemplazando x_i en la igualdad anterior obtenemos que

$$\begin{aligned} a_i^T (x_0 + \delta a_i) - b_i &= b_i - a_i^T x_0 \therefore 0 = 2b_i - a_i^T x_0 - a_i^T (x_0 + \delta a_i) \\ \therefore 0 &= 2b_i - 2a_i^T x_0 - \delta a_i^T a_i \\ \therefore 2b_i - 2a_i^T x_0 &= \delta a_i^T a_i \\ \therefore \frac{2(b_i - a_i^T x_0)}{a_i^T a_i} &= \frac{2(b_i - a_i^T x_0)}{\|a\|^2} = \delta. \end{aligned}$$

$$\text{Así, } x_i = x_0 + \frac{2(b_i - a_i^T x_0)}{\|a\|^2} a_i.$$

□

- c) We can also consider the sets

$$V_k = \{x \in \mathbb{R}^n : \|x - x_k\|_2 \leq \|x - x_i\|_2, i \neq k\}$$

The set V_k consists of points in \mathbb{R}^n for which the closest point in the set $\{x_0, \dots, x_K\}$ is x_k . The sets V_0, \dots, V_K give a polyhedral decomposition of \mathbb{R}^n . More precisely, the sets V_k are polyhedra, $\bigcup_{k=0}^K V_k = \mathbb{R}^n$, and $\text{int } V_i \cap \text{int } V_j = \emptyset$ for $i \neq j$, i.e., V_i and V_j intersect at most along a boundary. Suppose that P_1, \dots, P_m are polyhedra such that $\bigcup_{i=1}^m P_i = \mathbb{R}^n$, and $\text{int } P_i \cap \text{int } P_j = \emptyset$ for $i \neq j$. Can this polyhedral decomposition of \mathbb{R}^n be described as the Voronoi regions generated by an appropriate set of points?

Solución.

Considere dos hiperplanos $\mathcal{H}_1, \mathcal{H}_2 \subset \mathbb{R}^2$, los cuales no son paralelos. Considere que el ángulo entre los hiperplanos θ es tal que $0 < \theta < \frac{\pi}{3}$. Sean $x_1 \in P_1$ y $x_2 \in P_2$ dos puntos arbitrarios. Note que el punto \hat{x}_1 , el cual es el reflejo de x_1 respecto a \mathcal{H}_1 está en $\hat{P}_1 \subset P_4$. Similarmente, el punto \hat{x}_2 , el cual es el reflejo de x_2 respecto a \mathcal{H}_2 está en $\hat{P}_2 \subset P_4$. Sin embargo, no es posible construir el punto $\hat{x}_3 \in P_4$, el cual debe ser la reflexión de x_1 y x_2 respecto a \mathcal{H}_1 y \mathcal{H}_2 simultáneamente, ya que $\hat{P}_1 \cap \hat{P}_2 = \emptyset$.




Figura 3: Descomposición de \mathbb{R}^2 en cuatro poliedros.

□

2.10 Solution set of a quadratic inequality. Let $C \subseteq \mathbb{R}^n$ be the solution set of a quadratic inequality,

$$C = \{x \in \mathbb{R}^n : x^T A x + b^T x + c \leq 0\}$$

with $A \in \mathbb{S}^n$, $b \in \mathbb{R}^n$, and $c \in \mathbb{R}$. Are the converses of these statements true?

a) Show that C is convex if $A \succeq 0$.

Solución.

Un conjunto es convexo si su intersección con una línea arbitraria $y + tv$ es convexa. Considere entonces lo siguiente:

$$\begin{aligned} (y + tv)^T A (y + tv) + b^T (y + tv) + c &= (y^T A + tv^T A)(y + tv) + b^T y + b^T tv + c \\ &= y^T A y + 2y^T A tv + tv^T A tv + b^T y + b^T tv + c \\ &= (v^T A v)t^2 + (2y^T A v + b^T v)t + (b^T y + y^T A y + c) \\ &= (v^T A v)t^2 + (2y^T A v + b^T v)t + (b^T y + y^T A y + c) \\ &= \gamma t^2 + \mu t + \phi. \end{aligned}$$

Note que la intersección del conjunto solución C y la línea $y + tv$ es el conjunto $\{y + tv : \gamma t^2 + \mu t + \phi \leq 0\}$, el cual es convexo si $\gamma \geq 0$, lo cual se tiene ya que $A \succeq 0$. La afirmación recíproca no se tiene, ya que se pueden construir ejemplos en los que $A \preceq 0$, sin embargo C es convexo. □

b) Show that the intersection of C and the hyperplane defined by $g^T x + h = 0$ (where $g \neq 0$) is convex if $A + \lambda g g^T \succeq 0$ for some $\lambda \in \mathbb{R}$.

Solución.

Sea $B = A + \lambda g g^T$, entonces $A = B - \lambda g g^T$. Reemplazando en la desigualdad cuadrática:

$$\begin{aligned} x^T A x + b^T x + c &\leq 0 \quad \therefore x^T (B - \lambda g g^T) x + b^T x + c \leq 0 \\ \therefore x^T B x - \lambda x^T g g^T x + b^T x + c &\leq 0 \\ \therefore x^T B x + b^T x + (c - \lambda x^T g g^T x) &\leq 0. \end{aligned}$$

Por el literal anterior sabemos que el conjunto solución de la desigualdad obtenida es convexo, ya que $B \succeq 0$. Justamente, esta desigualdad representa la intersección entre C y el hiperplano, el cual también es convexo. □

2.13 Conic hull of outer products. Consider the set of rank- k outer products, defined as $\{X X^T : X \in \mathbb{R}^{n \times k}, \text{rank } X = k\}$. Describe its conic hull in simple terms.

Solución.

Sea $\mathcal{O} = \{X X^T : X \in \mathbb{R}^{n \times k}, \text{rank } X = k\}$. Observe que $X X^T$ es semidefinida positiva, ya que para un vector real y , $y^T X X^T y = z^T z = \|z\|^2 \geq 0$, con $z = X^T y$. Además, sabemos que $\text{rank } X X^T = \text{rank } X^T X = \text{rank } X^T = \text{rank } X = k$. Sean $A, B \in \mathcal{O}$ matrices semidefinidas positivas tal que $\text{rank } A = \text{rank } B = k$. Sea $v \in \ker(A + B)$, entonces

$$(A + B)v = 0 \quad \therefore \quad v^T (A + B)v = 0 \quad \therefore \quad v^T A v + v^T B v = 0,$$

por lo que $v^T A v = v^T B v = 0$, y en particular $Av = Bv = 0$. Por lo tanto, v está en los espacios nulos de A y B , es decir, $v \in \ker A$ y $v \in \ker B$. Así, $\dim(\ker A + B) \leq \dim(\ker A) + \dim(\ker B)$, y por el teorema de rango-nulidad, cualquier combinación $\gamma A + \delta B$ con $\gamma, \delta \geq 0$ debe tener rango mayor o igual que k , ya que al disminuir la nulidad, aumenta el rango. Por lo tanto, $\text{cone } \mathcal{O} = \{A : A \text{ es semidefinida positiva, } \text{rank } A \geq k\} \cup \{0_{n \times n}\}$. □

2.14 Expanded and restricted sets. Let $S \subseteq \mathbb{R}^n$, and let $\|\cdot\|$ be a norm on \mathbb{R}^n .

a) For $a \geq 0$ we define S_a as $\{x : \text{dist}(x, S) \leq a\}$, where $\text{dist}(x, S) = \inf_{y \in S} \|x - y\|$. We refer to S_a as S expanded or extended by a . Show that if S is convex, then S_a is convex.

Solución.

Sean $x, z \in S_a$. Queremos ver que la combinación convexa $\theta x + (1 - \theta)z \in S_a$. Note que

$$\text{dist}(\theta x + (1 - \theta)z, S) = \inf_{y \in S} \|\theta x + (1 - \theta)z - y\|.$$

Como $y \in S$ y S es convexo, considere el caso particular $y = \theta y_1 + (1 - \theta)y_2$. Luego,

$$\begin{aligned} \text{dist}(\theta x + (1 - \theta)z, S) &= \inf_{y_1, y_2 \in S} \|\theta x + (1 - \theta)z - \theta y_1 - (1 - \theta)y_2\| \\ &= \inf_{y_1, y_2 \in S} \|\theta(x - y_1) + (1 - \theta)(z - y_2)\| \\ &\leq \theta \inf_{y_1 \in S} \|x - y_1\| + (1 - \theta) \inf_{y_2 \in S} \|z - y_2\| \\ &\leq (\theta + (1 - \theta))a \\ &\leq a. \end{aligned}$$

□

- b) For $a \geq 0$ we define $S_{-a} = \{x : B(x, a) \subseteq S\}$, where $B(x, a)$ is the ball (in the norm $\|\cdot\|$), centered at x , with radius a . We refer to S_{-a} as S shrunk or restricted by a , since S_{-a} consists of all points that are at least a distance a from $\mathbb{R}^n \setminus S$. Show that if S is convex, then S_{-a} is convex.

Solución.

Sean $x, y \in S_{-a}$, y sea z tal que $|z| \leq a$. Entonces $x + z, y + z \in S$, por lo que para $0 \leq \theta \leq 1$ se tiene que $\theta x + (1 - \theta)y + z \in S$, ya que S es convexo. Por lo tanto $\theta x + (1 - \theta)y \in S_{-a}$.

□

2.15 *Some sets of probability distributions.* Let x be a real-valued random variable with $\mathbf{prob}(x = a_i) = p_i, i = 1, \dots, n$, where $a_1 < a_2 < \dots < a_n$. Of course $p \in \mathbb{R}^n$ lies in the standard probability simplex $P = \{p : \mathbf{1}^T p = 1, p \succeq 0\}$. Which of the following conditions are convex in p ? (That is, for which of the following conditions is the set of $p \in P$ that satisfy the condition convex?)

- a) $\alpha \leq \mathbf{E} f(x) \leq \beta$, where $\mathbf{E} f(x)$ is the expected value of $f(x)$, i.e., $\mathbf{E} f(x) = \sum_{i=1}^n p_i f(a_i)$. (The function $f : \mathbb{R} \rightarrow \mathbb{R}$ is given.)

Solución.

Esta condición es convexa en p , ya que es equivalente a la desigualdad lineal $\alpha \leq \sum_{i=1}^n p_i f(a_i) \leq \beta$.

□

- b) $\mathbf{prob}(x > \alpha) \leq \beta$.

Solución.

Esta condición es convexa en p , ya que es equivalente a la desigualdad lineal $\sum_{i: a_i \geq \alpha} p_i \leq \beta$.

□

- c) $\mathbf{E} |x^3| \leq \alpha \mathbf{E} |x|$.

Solución.

Esta condición es convexa en p , ya que es equivalente a la desigualdad lineal

$$\sum_{i=1}^n p_i |a_i|^3 \leq \alpha \sum_{i=1}^n p_i |a_i| = \sum_{i=1}^n p_i (|a_i|^3 - \alpha |a_i|) \leq 0.$$

□

- d) $\mathbf{E} x^2 \leq \alpha$.

Solución.

Esta condición es convexa en p , ya que es equivalente a la desigualdad lineal $\sum_{i=1}^n p_i (a_i)^2 \leq \alpha$.

□

- e) $\mathbf{E} x^2 \geq \alpha$.

Solución.

Esta condición es convexa en p , ya que es similar a la del literal anterior.

□

f) $\text{var}(x) \leq \alpha$, where $\text{var}(x) = \mathbf{E}(x - \mathbf{E}x)^2$ is the variance of x .

Solución.

Considere la distribución de probabilidad $\{\mathbf{prob}(x = a_1 = 0) = 0, \mathbf{prob}(x = a_2 = 1) = 1\}$. Sea $\alpha = \frac{1}{8}$. Entonces

$$\text{var}(x) = (0 \cdot 0^2 + 1 \cdot 1^2) - (0 \cdot 0 + 1 \cdot 1)^2 = 1 - 1 = 0 \leq \frac{1}{8}.$$

Sin embargo, al considerar la distribución $\{\mathbf{prob}(x = a_1 = 0) = \frac{1}{3}, \mathbf{prob}(x = a_2 = 1) = \frac{2}{3}\}$, podemos ver que $\text{var}(x)$ no es convexa en general, ya que

$$\left(\frac{1}{3} \cdot 0^2 + \frac{2}{3} \cdot 1^2\right) - \left(\frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1\right)^2 = \frac{2}{9} \not\leq \frac{1}{8}.$$

□

g) $\text{var}(x) \geq \alpha$.

Solución.

Observe que esta condición la podemos reescribir como

$$\sum_{i=1}^n p_i (a_i)^2 - \left(\sum_{i=1}^n p_i a_i\right)^2 \geq \alpha \quad \therefore - \sum_{i=1}^n p_i (a_i)^2 + \left(\sum_{i=1}^n p_i a_i\right)^2 \leq \alpha$$

$$\therefore b^T p + p^T a a^T p \leq \alpha,$$

donde $b = a_i^2$. Esto es un conjunto convexo dado que $a a^T$ es semidefinida positiva.

□

h) $\mathbf{quartile}(x) \geq \alpha$, where $\mathbf{quartile}(x) = \inf\{\beta : \mathbf{prob}(x \leq \beta) \geq 0.25\}$.

Solución.

□

i) $\mathbf{quartile}(x) \leq \alpha$.

Solución.

□

2.16 Show that if S_1 and S_2 are convex sets in \mathbb{R}^{m+n} , then so is their partial sum

$$S = \{(x, y_1 + y_2) : x \in \mathbb{R}^m, y_1, y_2 \in \mathbb{R}^n, (x, y_1) \in S_1, (x, y_2) \in S_2\}$$

Solución.

Sean $\mathbf{x}_1, \mathbf{x}_2 \in S$ tales que $x_1 = (\tilde{x}, \tilde{y}_1 + \tilde{y}_2)$, $x_2 = (\hat{x}, \hat{y}_1 + \hat{y}_2)$ tal que $(\tilde{x}, \tilde{y}_1), (\hat{x}, \hat{y}_1) \in S_1$ y $(\tilde{x}, \tilde{y}_2), (\hat{x}, \hat{y}_2) \in S_2$. Considere la siguiente combinación convexa:

$$\begin{aligned} \mathbf{x}_1 + \mathbf{x}_2 &= \theta(\tilde{x}, \tilde{y}_1 + \tilde{y}_2) + (1 - \theta)(\hat{x}, \hat{y}_1 + \hat{y}_2) \\ &= (\theta\tilde{x}, \theta\tilde{y}_1 + \theta\tilde{y}_2) + ((1 - \theta)\hat{x}, (1 - \theta)\hat{y}_1 + (1 - \theta)\hat{y}_2) \\ &= (\theta\tilde{x} + (1 - \theta)\hat{x}, (\theta\tilde{y}_1 + (1 - \theta)\hat{y}_1) + (\theta\tilde{y}_2 + (1 - \theta)\hat{y}_2)) \end{aligned}$$

Como S_1 y S_2 son convexos, entonces $(\theta\tilde{x} + (1 - \theta)\hat{x}, \theta\tilde{y}_1 + (1 - \theta)\hat{y}_1) \in S_1$ y $(\theta\tilde{x} + (1 - \theta)\hat{x}, \theta\tilde{y}_2 + (1 - \theta)\hat{y}_2) \in S_2$. Por lo tanto, $\mathbf{x}_1 + \mathbf{x}_2 \in S$.

□

2.17 *Image of polyhedral sets under perspective function.* In this problem we study the image of hyperplanes, halfspaces, and polyhedra under the perspective function $P(x, t) = x/t$, with $\text{dom } P = \mathbb{R}^n \times \mathbb{R}_{++}$. For each of the following sets C , give a simple description of

$$P(C) = \{v/t : (v, t) \in C, t > 0\}.$$

- a) The polyhedron $C = \text{conv}\{(v_1, t_1), \dots, (v_K, t_K)\}$ where $v_i \in \mathbb{R}^n$ and $t_i > 0$.
- b) The hyperplane $C = \{(v, t) : f^T v + gt = h\}$ (with f and g not both zero).
- c) The halfspace $C = \{(v, t) : f^T v + gt \leq h\}$ (with f and g not both zero).
- d) The polyhedron $C = \{(v, t) : Fv + gt \leq h\}$.

2.18 Invertible linear-fractional functions. Let $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ be the linear-fractional function

$$f(x) = (Ax + b)/(c^T x + d), \quad \text{dom } f = \{x : c^T x + d > 0\}$$

Suppose the matrix

$$Q = \begin{bmatrix} A & b \\ c^T & d \end{bmatrix}$$

is nonsingular. Show that f is invertible and that f^{-1} is a linear-fractional mapping. Give an explicit expression for f^{-1} and its domain in terms of A, b, c , and d . *Hint.* It may be easier to express f^{-1} in terms of Q .

Solución.

Sea $x \in \mathbb{R}^n$. Considere la función $\mathcal{P}(x) = \{s(x, 1) : s \geq 0\}$, la cual envía a vectores en \mathbb{R}^n en rayos de \mathbb{R}^{n+1} . Sea P la función perspectiva, entonces f puede ser expresada como

$$\begin{aligned} P(Q\mathcal{P}(x)) &= P(Q \cdot s(x, 1)) \\ &= P\left(\begin{bmatrix} A & b \\ c^T & d \end{bmatrix} \begin{pmatrix} sx \\ s \end{pmatrix}\right) \\ &= P\left(\begin{bmatrix} s(Ax + b) \\ s(c^T x + d) \end{bmatrix}\right) \\ &= \frac{s(Ax + b)}{s(c^T x + d)} = \frac{Ax + b}{c^T x + d} \\ &= f(x). \end{aligned}$$

Como P, \mathcal{P} y Q tienen inversas — Q tiene inversa ya que es no singular—, entonces la inversa de f es

$$f^{-1}(x) = \mathcal{P}^{-1}(Q^{-1}P^{-1}(x)).$$

□

Ejercicios adicionales

- Implementar un algoritmo para determinar el cono convexo de un conjunto de puntos en cualquier dimensión.
- Verificar que el conjunto de soluciones de un conjunto de desigualdades de matrices lineales es convexa.

Solución.

Sea $\mathcal{A}(x) = [A_1, A_2, \dots, A_n](x_1, x_2, \dots, x_n)^T$. Considere la desigualdad lineal de matrices

$$\mathcal{A}(x) = x_1 A_1 + x_2 A_2 + x_3 A_3 + \dots + x_n A_n \preceq B.$$

Note que la solución de la desigualdad anterior es el conjunto $\{x : \mathcal{A}(x) \preceq B\} = f^{-1}(\mathbf{S}_+^m)$, donde f es la función afín $f : \mathbb{R}^n \rightarrow \mathbf{S}^m$ definida por $f(x) = B - \mathcal{A}(x)$. Que el conjunto $\{x : \mathcal{A}(x) \preceq B\}$ sea convexo sigue de que f es afín.

□

Referencias

- [1] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2009.